

Makine Öğrenmesi

Doğrusal Regresyon
İlhan AYDIN


- Birçok boyutlu lineer regresyon
- Bileşik özellikler, lineer olmayan ilişki modelleme
- Model oluşturma
- Ek: *lineer regresyon normal denklemleri*

Ders planı

- Regresyon probleminde, olayın modeli sürekli bir modeldir, yani
- Modelleneyecek değişkenler **sürekli** şekilde değişmesi gerekiyor
- Makine öğrenme problemi, bu modelleneyecek değişkenlerin değişimi için karar verme için uygun modeli oluşturmak

Regresyon problemi

- Verilen
 - Veri $X = \{x_1, \dots, x_n\}$ burada x_i d boyutlu uzaydadır.
 - Verilee karşılık gelecek etiketler $y = \{y_1, \dots, y_n\}$ ve y_i değerleri reel sayıdır.



Regresyon problemi

- 67 örnek eğitim / 30 teste bölünmüş toplam 97 örnek
- Sekiz tahmin edici (özellikler):
 - – 6 sürekli (4 log dönüşümü), 1 binary, 1 sıralı
- Sürekli sonuç değişkeni:
 - lpsa: log(prostat spesifik anİgen seviyesi)


Term	Coefficient	Std. Error	Z Score
Intercept	2.46	0.09	27.60
lcavol	0.68	0.13	5.37
lweight	0.26	0.10	2.75
age	-0.14	0.10	-1.40
lbph	0.21	0.10	2.06
svi	0.31	0.12	2.47
lcp	-0.29	0.15	-1.87
gleason	-0.02	0.15	-0.15
pgg45	0.27	0.15	1.74

Prostat Kanser Veri Kümesi

- Hipotez:

$$y = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_d x_d = \sum_{j=0}^d \theta_j x_j$$

- Karesi alınan hataların toplamını en aza indirerek modeli sığdır





En küçük kareler
Uydurma çizgi, tahmin edici
olarak kullanılır

Doğrusal Regresyon

- Maliyet fonksiyonu:

$$J(\theta) = \frac{1}{2n} \sum_{i=1}^n \left(h_{\theta} \left(x^{(i)} \right) - y^{(i)} \right)^2$$

$\min_{\theta} J(\theta)$ değerini bul




En Küçük Kareler Doğrusal Regresyon

$$J(\theta) = \frac{1}{2n} \sum_{i=1}^n \left(h_{\theta} \left(x^{(i)} \right) - y^{(i)} \right)^2$$

J 'yi gözmek için elimizde x giriş özellikleri mevcut. O zaman aşağıdaki iki parametreyi ayarlamak gerekir.

$$\theta = [\theta_0, \theta_1]$$





$$J([0, 0.5]) = \frac{1}{2 \times 3} [(0.5 - 1)^2 + (1 - 2)^2 + (1.5 - 3)^2] \approx 0.58$$

Maliyet Fonksiyonunun Arkasındaki Fikir


$$J(\theta) = \frac{1}{2n} \sum_{i=1}^n \left(h_{\theta} \left(x^{(i)} \right) - y^{(i)} \right)^2$$

J 'yi gözmek için elimizde x giriş özellikleri mevcut. O zaman aşağıdaki iki parametreyi ayarlamak gerekir.

$$\theta = [\theta_0, \theta_1]$$




Maliyet Fonksiyonunun Arkasındaki Fikir



Maliyet Fonksiyonunun Arkasındaki Fikir


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$


(function of the parameters θ_0, θ_1)



Maliyet Fonksiyonunun Arkasındaki Fikir


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$


(function of the parameters θ_0, θ_1)



Maliyet Fonksiyonunun Arkasındaki Fikir


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)




$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Maliyet Fonksiyonunun Arkasındaki Fikir

- θ değeri için başlangıç değeri seç
- Minimuma ulaşıncaya kadar devam et
 - $J(\theta)$ 'yı azaltacak θ için yeni değerleri seç



Temel Arama Prosedürü

- θ değeri için başlangıç değeri seç
- Minimuma ulaşıncaya kadar devam et
 - $J(\theta)$ 'yı azaltacak θ için yeni değerleri seç

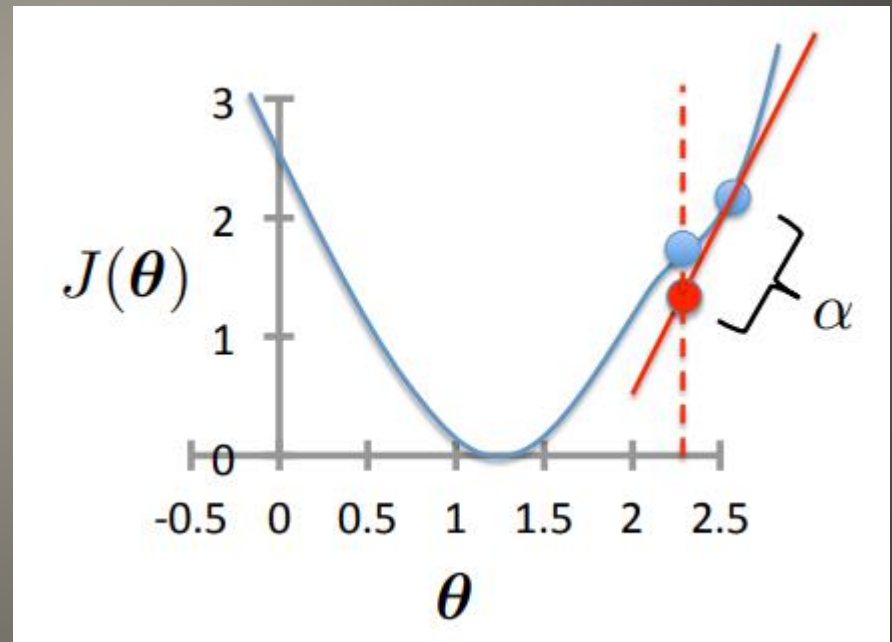


En küçük kareler amaç fonksiyonu dışbükey (içbükey) olduğundan, yerel minimumlar hakkında endişelenmemize gerek yoktur.

Temel Arama Prosedürü

- θ değerlerini başlat
- Yakınsama sağlanana kadar
 - $\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$ $j=0,1,\dots,d$ için anlık güncelleme

Öğrenme oranı $\alpha=0.05$
gibi küçük bir değer seçilir



Dereceli Azaltma

- θ değerlerini başlat
- Yakınsama sağlanana kadar
 - $\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$ $j=0,1,\dots,d$ için anlık güncelleme

Lineer regresyon için:
$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{\partial}{\partial \theta_j} \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Dereceli Azaltma

- θ değerlerini başlat
- Yakınsama sağlanana kadar
 - $\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$ $j=0,1,\dots,d$ için anlık güncelleme

$$\begin{aligned} \text{Lineer regresyon için: } \frac{\partial}{\partial \theta_j} J(\theta) &= \frac{\partial}{\partial \theta_j} \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2 \\ &= \frac{\partial}{\partial \theta_j} \frac{1}{2n} \sum_{i=1}^n \left(\sum_{k=0}^d \theta_k x_k^{(i)} - y^{(i)} \right)^2 \end{aligned}$$

Dereceli Azaltma

- θ değerlerini başlat
- Yakınsama sağlanana kadar
 - $\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$ $j=0,1,...,d$ için anlık güncelleme

Lineer regresyon için


$$\begin{aligned}
 \frac{\partial}{\partial \theta_j} J(\theta) &= \frac{\partial}{\partial \theta_j} \frac{1}{2n} \sum_{i=1}^n \left(h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)} \right)^2 \\
 &= \frac{\partial}{\partial \theta_j} \frac{1}{2n} \sum_{i=1}^n \left(\sum_{k=0}^d \theta_k x_k^{(i)} - y^{(i)} \right)^2 \\
 &= \frac{1}{n} \sum_{i=1}^n \left(\sum_{k=0}^d \theta_k x_k^{(i)} - y^{(i)} \right) \times \frac{\partial}{\partial \theta_j} \left(\sum_{k=0}^d \theta_k x_k^{(i)} - y^{(i)} \right) \\
 &= \frac{1}{n} \sum_{i=1}^n \left(\sum_{k=0}^d \theta_k x_k^{(i)} - y^{(i)} \right) x_j^{(i)}
 \end{aligned}$$

Dereceli Azaltma

- **Dereceli azaltma** (gradient descent) metodu, çok güçlü ve çok genel **optimizasyon metodudur**
 - Bir (θ_0, θ_1) noktasında başlıyoruz
 - Devamlı, J' 'nin değerlerini azaltmak için (θ_0, θ_1) uzayda küçük adımlarını yapıyoruz
 - J' 'nin değerleri sürekli düşmek zorunda
 - Çünkü $J \geq 0$, bu süreç sonunda bir noktaya gelmek zorundadır (sonsuz devam edemez yani)

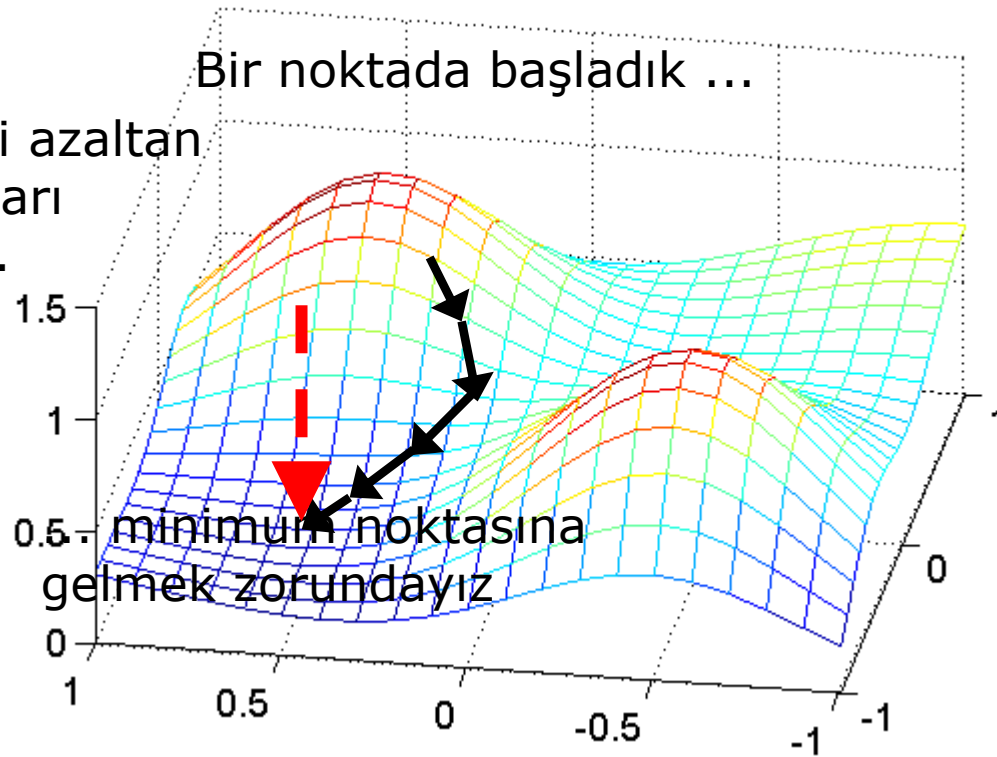
Dereceli azaltma metodu

Azaltılacak fonksiyon




Dereceli azaltma metodu

... J değerini azaltan
küçük adımları
yapıyoruz ...




Dereceli azaltma metodu

Sadece **lokal olarak bir minimumdur**: başka noktadan başlayınca başka noktaya gelmek mümkündür



Dereceli azaltma metodu

Genellikle, bu metot birkaç rastgele başlangıç nokta ile çalıştırılmalı, ve en iyi minimum seçilmeli



Dereceli azaltma metodu

- Ortadaki adımları, J değerini en çok azaltması isteriz
- Bunun için, adımları “**gradient**” (yani eğim) yönünde yapılmaktadır
- Dereceli azaltma algoritması:
 - **Yakınsamaya kadar** tekrarlama {

$j=1,2$ için;
}

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Dereceli azaltma metodu

- Yakınsamaya kadar tekrarlayın {
 $\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$
 $j=1,2$ için;
}

Dereceli azaltma metodu

- Bu formülde

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Değer güncelleştirilmesi

Maliyet fonksiyonunun türevleri

Özel bir parametre (öğrenme hız parametresi)

Dereceli azaltma metodu

- Yakınsamaya kadar tekrarlayın {
$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

 $j=1,2$ için;
}

Önemli Not:

Türevler, şu andaki (θ_0, θ_1) noktası için hepsi döngüden önce hesaplanmalı. Sonra, θ_0 ve θ_1 değerleri güncelleştirilmesi gerekiyor.

θ_0, θ_1 'nin güncelleştirilmesi türevler hesaplanmasıyla aynı zamanda yapılmaz ! yani, (θ_0, θ_1) parça-parça şekilde güncelleştirilmez!

Dereceli azaltma metodu

- Yakınsamaya kadar tekrarlayın {

$j=1,2$ için;

}

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Yakınsamaya kadar tekrarlayın {

$$\theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

} **Dereceli azaltma metodu**

- Yakınsamaya kadar tekrarlayın {

$j=1,2$ için;
}

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Yakınsamaya kadar tekrarlayın {

$$\theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

}

Yanlış

İlk adımda değişmiş oldu !!

Dereceli azaltma metodu

- Yakınsamaya kadar tekrarlayın {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

$j=1,2$ için;

Doğru

~~Yakınsamaya kadar tekrarlayın {~~ ~~Yakınsamaya kadar tekrarlayın {~~

~~$$\theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$~~

~~$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$~~

~~$$temp_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$~~

~~$$temp_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$~~

~~$$\theta_0 := temp_0$$~~

~~$$\theta_1 := temp_1$$~~

AYNI !

Dereceli azaltma metodu

- Lineer regresyonu


$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2$$

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (\bar{\theta}_0 + \bar{\theta}_1 x^i - y^i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m x^i \cdot (\bar{\theta}_0 + \bar{\theta}_1 x^i - y^i)$$

Dereceli azaltma metodu


- Alpha seçme (biraz dikkat edilmeli)
 - Küçük alpha – yavaş yakınsama
 - Büyük alpha – ilerli geri yakınsama



Dereceli azaltma metodu

- Alpha seçme

- Küçük alpha – yavaş yakınsama
- Büyük alpha – ilerli geri yakınsama




yavaş!

Dereceli azaltma metodu

- Alpha seçme
 - Küçük alpha – yavaş yakınsama
 - Büyük alpha – ilerli geri yakınsama

İleri geri yakınsama !




Dereceli azaltma metodu

- Alpha seçme
 - Küçük alpha – yavaş yakınsama
 - Büyük alpha – ilerli geri yakınsama
- İyi bir alpha seçmek için, birkaç alpha değerini denemek lazım
- Bu değerler için, dereceli azaltma metodunu çalıştırıp performansını incelemek lazım


Tipik denenecek alpha değerleri:

$\alpha = 0.001, 0.003, 0.01, 0.03, 0.1, 0.3, 1, 3, 10, \dots$

yavaş yavaş
 **iyi**
ilerli geri
ilerli geri hkt

Dereceli azaltma metodu

Örnek)




x	y
0	1
1	2
2	3

Doğrusal regresyon yöntemiyle veriden model çıkarın?

El ile Doğrusal Regresyon Çözümü

Örnek)



x	y
0	1
1	2
2	3

Doğrusal regresyon yöntemiyle veriden model çıkarın?

Çözüm) Model polinomunu $h_0(x) = \theta_0 + \theta_1 x_1$

Başlangıç aşamasında $\theta_0 = 0$ $\theta_1 = 0$

θ kullanılarak x girişlerine karşılık hipotez tahminlerini hesaplayalım:

x	$h_0(x)$	y	Hata
0	$0 + 0 \cdot 0 = 0$	1	-1
1	$0 + 0 \cdot 1 = 0$	2	-2
2	$0 + 0 \cdot 2 = 0$	3	-3

El ile Doğrusal Regresyon Çözümü

Çözüm) Model polinomu $h_{\theta}(x) = \theta_0 + \theta_1 x_1$

Başlangıç aşamasında $\theta_0 = 0$ $\theta_1 = 0$

θ kullanılarak x girişlerine karşılık hipotez tahminlerini hesaplayalım:

x	$h_{\theta}(x)$	y	Hata
0	$0 + 0 \cdot 0 = 0$	1	-1
1	$0 + 0 \cdot 1 = 0$	2	-2
2	$0 + 0 \cdot 2 = 0$	3	-3

Ortalama maliyeti hesaplayalım: $J(\theta) = \frac{1}{2n} \cdot \sum_{i=1}^n (h_{\theta}(x_i) - y_i)^2$

$$J(\theta) = \frac{1}{2 \cdot 3} \sum_{i=1}^3 (h_{\theta}(x_i) - y_i)^2 = \frac{1}{6} ((-1)^2 + (-2)^2 + (-3)^2) = \frac{14}{6}$$

El ile Doğrusal Regresyon Çözümü

Ortalama maliyeti hesaplayalım: $J(\theta) = \frac{1}{2n} \cdot \sum_{i=1}^n (h_{\theta}(x_i) - y_i)^2$

$$J(\theta) = \frac{1}{2 \cdot 3} \sum_{i=1}^3 (h_{\theta}(x_i) - y_i)^2 = \frac{1}{6} \left((-1)^2 + (-1)^2 + (-3)^2 \right) = \frac{14}{6}$$

Şimdi ortalama hatanın her bir parametreye türevini alarak parametreleri uygun yönde güncelleyelim

$$\theta_j = \theta_j - \alpha \cdot \frac{\partial J(\theta)}{\partial \theta_j}$$

$$\frac{\partial J(\theta)}{\partial \theta_0} = \frac{1}{n} \sum_{i=1}^n \left(\overbrace{\theta_0 + \theta_1 x_i}^{h_{\theta}(x_i)} - y_i \right) \cdot 1 = \frac{1}{3} \left[(-1) + (-2) + (-3) \right] = -2$$

$$\frac{\partial J(\theta)}{\partial \theta_1} = \frac{1}{n} \sum_{i=1}^n (\theta_0 + \theta_1 x_i - y_i) \cdot x_i = \frac{1}{3} \left[(-1) \cdot 0 + (-2) \cdot 1 + (-3) \cdot 2 \right] = \frac{-8}{3} = -2.6$$

$$\alpha = 0.1, \quad \theta_0 = 0 - (0.1) \cdot (-2) = 0.2$$

$$\theta_1 = 0 - (0.1) \cdot (-2.6) = 0.26$$

El ile Doğrusal Regresyon Çözümü