


Makine Öğrenmesi


K- En Yakın Komşu Sınıflandırma
İlhan AYDIN

- Bütün makine öğrenmesi sınıflandırıcılarından en basitidir.
- Temel fikir: yeni bir noktası etiketi bilinen en yakın noktaya göre etiketle.



1- En Yakın Komşu

- Örnek tabanlı öğrenme tipi
 - Aynı zamanda hafıza tabanlı öğrenme olarak bilinir.
 - Görev: Hedefi tahmin et/yeni veri noktasının etiketi



Eğitim kümesindeki en benzer veri noktasına bakınız.

1- En Yakın Komşu

- 1-En Yakın Komşu Eğitim Adımı

Verilen : $\langle x^{[i]}, y^{[i]} \rangle \in \mathcal{D} \quad |\mathcal{D}| = n$
 $\langle x^{[q]}, ? \rangle$

Tahmin algoritması: $f(x^{[q]})$

Enyakin_nokta=None

enyakin_mesafe= ∞

For $i=1 \dots n$:

 mevcut_mesafe= $d(x^{[i]}, x^{[q]})$

 if $mevcut_mesafe < enyakin_mesafe$:

 Enyakin_mesafe=mevcut_mesafe

 Enyakin_nokta= $x^{[i]}$

Return $f(enyakin_nokta)$





Sorgu noktası



1- En Yakın Komşu



- En yakın komşu sınıflandırma modelinin karar sınırı nasıl oluşturulur?
- Öklid uzaklığı metriğini varsayarsak, herhangi iki eğitim örneği a ve b arasındaki karar sınırı düz bir çizgidir.
- Karar sınırında bir sorgu noktası bulunuyorsa, bunun hem eğitim örneği a hem de b 'ye eşit uzaklıkta olduğu anlamına gelir.
- Bir çift nokta arasındaki karar sınırı düz bir çizgi iken, NN modelinin küresel düzeydeki karar sınırı, tüm eğitim seti göz önüne alındığında, birbirine bağlı, dışbükey çokyüzlüler kümesidir.
- Bir çokyüzlü içindeki tüm noktalar, içindeki eğitim örneğine en yakın olanlardır ve çokyüzlü dışındaki tüm noktalar, farklı bir eğitim örneğine daha yakındır.

1- En Yakın Komşu



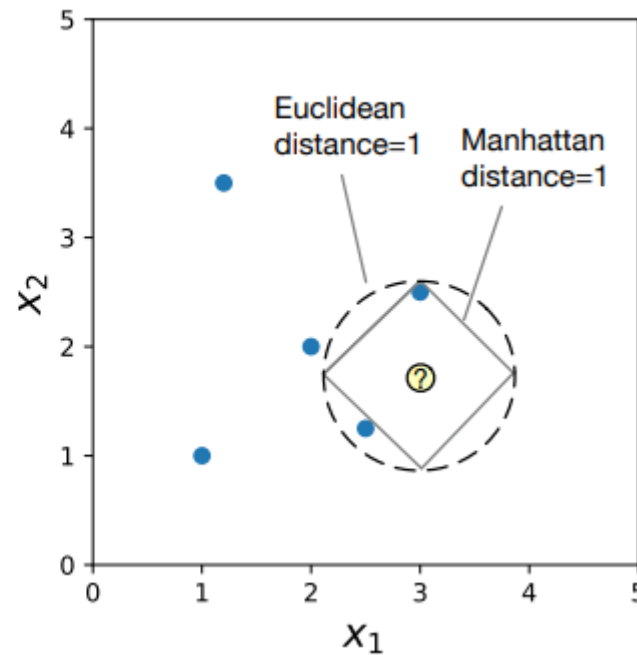

İki eğitim örneği (a & b, a & c ve c & d) ve sonuçta ortaya çıkan Voronoi diyagramı (sağ alt köşe) arasındaki doğrusal segmentler aracılığıyla iki boyutlu bir veri kümesinin (x_1 ve x_2 özellikleri) düzlem bölümlenmesinin gösterimi.

1- En Yakın Komşu



1- En Yakın Komşu

Hangisi en yakın?



Kullanılan mesafe ölçüm aracına göre değişir?

1- En Yakın Komşu

Euclidean

Manhattan

Minkowski:
$$d(\mathbf{x}^{[a]}, \mathbf{x}^{[b]}) = \left[\sum_{j=1}^m \left(\left| x_j^{[a]} - x_j^{[b]} \right| \right)^p \right]^{\frac{1}{p}}$$

Mahalanobis

Cosine similarity

**Bazı Ortak Sürekli mesafe
Ölçümleri**



Hamming distance: $d(\mathbf{x}^{[a]}, \mathbf{x}^{[b]}) = \sum_{j=1}^m |x_j^{[a]} - x_j^{[b]}|$ where $x_j \in \{0,1\}$

Jaccard/Tanimoto similarity:


$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$

Dice: $D(A, B) = \frac{2|A \cap B|}{|A| + |B|}$

Bazı Ortak Ayırık mesafe Ölçümleri



Özellik Ölçekleme



K-En Yakın Komşu

A

y:          

Çoğunluk oylama



Çoklu oylama



B

y:          

Çoğunluk oylama

None

Çoklu oylama



K-En Yakın Komşu

- Her bir özellik boyutuna özellik ölçeklemeye eşdeğer bir ağırlık ekleyerek mesafe ölçümlerini değiştirebiliriz.
- Öklid mesafesi durumunda, bu aşağıdaki gibi görünecektir.

$$d_w(\mathbf{x}^{[a]}, \mathbf{x}^{[b]}) = \sqrt{\sum_{j=1}^m w_j (x_j^{[a]} - x_j^{[b]})^2},$$

- Bunu kodda verimli bir şekilde uygulamak için, ağırlıklandırmayı bir dönüşüm matrisi olarak ifade edebiliriz; burada dönüşüm matrisi, m özellikleri için m ağırlık katsayılarından oluşan bir köşegen matristir:

$$\mathbf{W} \in \mathbb{R}^{m \times m} = \text{diag}(w_1, w_2, \dots, w_m).$$

$$d_w(\mathbf{x}^{[a]}, \mathbf{x}^{[b]}) = \sqrt{(\mathbf{x}^{[a]} - \mathbf{x}^{[b]})^T \mathbf{W} (\mathbf{x}^{[a]} - \mathbf{x}^{[b]})}.$$

K-En Yakın Komşu Özellik Ağırlıklandırma

- kNN'nin bir çeşidi, mesafe ağırlıklı kNN'dir.
- “Normal” kNN'de, tüm k komşular benzer şekilde çoğulcu oylama veya ortalamaya katılır.
- Ancak, özellikle bir komşu kümesini çevreleyen yarıçap büyükse, sorgu noktasına "daha yakın" olan komşulara daha güçlü bir ağırlık vermek isteyebiliriz.
- Örneğin, kNN sınıflandırmasında komşulara w ağırlığı atayabiliriz,:
- $$w^{[i]} = \frac{1}{d(x^{[i]}, x^{[q]})}$$

K-En Yakın Komşu Mesafe Ağırlıklandırma