

Lojistik Regresyon

Giriş


Doç. Dr. İlhan AYDIN

- Olasılığa Dayalı Sınıflandırma

- Sadece sınıfı tahmin etmek yerine, örneğin o sınıf olma olasılığını verin
 - Örneğin, $p(y | x)$
- Algılayıcı ile karşılaştırma
 - Algılayıcı bir olasılık tahmini üretmiyor
 - Algılayıcı (ve diğer ayırmacı sınıflandırıcılar) yalnızca ayırmacı bir model üretmekle ilgilenirler.
- Hatırlatma:

$$0 \leq p(\text{event}) \leq 1$$

$$p(\text{event}) + p(\neg \text{event}) = 1$$



Lojistik Regresyon


- Lojistik Regresyon

- Ayırt edici işlevleri öğrenmek için olasılıksal bir yaklaşım benimser (yani, bir sınıflandırıcı)
- $h_0(x)$ $p(y = 1 | x; \theta)$ 'yi vermeli
- $0 \leq h_0(x) \leq 1$ (Sadece bir eşik ile doğrusal regresyon kullanamazsınız)
- Lojistik regresyon modeli:

$$h_{\theta}(x) = g(\theta^T x)$$

$$g(z) = \frac{1}{1 + e^{-z}}$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$



Lojistik Regresyon

- Hipotez Çıktısının Yorumlanması

- $h_0(x)$ tahmini $p(y = 1 | x; \theta)$

Example: Cancer diagnosis from tumor size

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tumorSize} \end{bmatrix}$$

$$h_{\theta}(\mathbf{x}) = 0.7$$

→ Tell patient that 70% chance of tumor being malignant

- Not: $p(y = 0 | x; \theta) + p(y = 1 | x; \theta) = 1$
- Öyleyse, $p(y = 0 | x; \theta) = 1 - p(y = 1 | x; \theta)$

Lojistik Regresyon

- Başka Bir Yorum

- Eşdeğer olarak, lojistik regresyon şunu varsayar:

$$\log \underbrace{\frac{p(y = 1 \mid \mathbf{x}; \boldsymbol{\theta})}{p(y = 0 \mid \mathbf{x}; \boldsymbol{\theta})}}_{\text{odds of } y = 1} = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d$$


- Not: Bir olayın lehine olan oran, $p / (1 - p)$ miktarıdır, burada p , olayın olasılığıdır
- Diğer bir deyişle, lojistik regresyon, log oranlarının x 'in doğrusal bir fonksiyonu olduğunu varsayar.

Lojistik Regresyon


- Lojistik Regresyon

$$h_{\theta}(x) = g(\theta^T x)$$

$$g(z) = \frac{1}{1 + e^{-z}}$$




- $\theta^T x$, negatif örnekler için büyük negatif değerler olmalıdır.
- $\theta^T x$, pozitif örnekler için büyük pozitif değerler olmalıdır.
- Bir eşik varsayalım ve..
 - $h_0(x) \geq 0.5$ ise $y=1$ tahmin et
 - $h_0(x) < 0.5$ ise $y=0$ tahmin et



Lojistik Regresyon

- Doğrusal Olmayan Karar Sınırı
 - Lineer regresyonda olduğu gibi, temel fonksiyon genişletmesini özelliklere uygulayabilir

$$\mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \end{bmatrix} \rightarrow \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ x_1 x_2 \\ x_1^2 \\ x_2^2 \\ x_1^2 x_2 \\ x_1 x_2^2 \\ \vdots \end{bmatrix}$$



Lojistik Regresyon

- Lojistik Regresyon

- $\{(x^1, y^1), (x^2, y^2), \dots (x^n, y^n)\}$ verildiğinde
 $x^i \in \mathbb{R}, y^i \in \{0, 1\}$
- Model:

$$h_{\theta}(\mathbf{x}) = g(\boldsymbol{\theta}^T \mathbf{x})$$

$$g(z) = \frac{1}{1 + e^{-z}}$$

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_d \end{bmatrix}$$

$$\mathbf{x}^T = \begin{bmatrix} 1 & x_1 & \dots & x_d \end{bmatrix}$$

Lojistik Regresyon

- Lojistik Regresyon Amaç Fonksiyonu
 - Doğrusal regresyonda olduğu gibi sadece kare kaybı kullanamazsınız:

$$J(\theta) = \frac{1}{2n} \sum_{i=1}^n \left(h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)} \right)^2$$

- Lojistik regresyon modelini kullanma

$$h_{\theta}(\mathbf{x}) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

- Dışbükey olmayan bir optimizasyonla sonuçlanır

Lojistik Regresyon

- Maksimum Olabilirlik Tahmini ile Maliyet Fonksiyonunun Türetilmesi

- Veri olasılığı şu şekilde verilir:

$$l(\theta) = \prod_{i=1}^n p(y^{(i)} | \mathbf{x}^{(i)}; \theta)$$

- Bu nedenle, olasılığı en üst düzeye çıkaran θ 'yi arayın.

$$\theta_{\text{MLE}} = \arg \max_{\theta} l(\theta) = \arg \max_{\theta} \prod_{i=1}^n p(y^{(i)} | \mathbf{x}^{(i)}; \theta)$$

- Çözümü değiştirmeden kayıtları alabilir:

$$\begin{aligned} \theta_{\text{MLE}} &= \arg \max_{\theta} \log \prod_{i=1}^n p(y^{(i)} | \mathbf{x}^{(i)}; \theta) \\ &= \arg \max_{\theta} \sum_{i=1}^n \log p(y^{(i)} | \mathbf{x}^{(i)}; \theta) \end{aligned}$$

Lojistik Regresyon

- Maksimum Olabilirlik Tahmini ile Maliyet Fonksiyonunun Türetilmesi
 - Aşağıdaki gibi genişletin

$$\begin{aligned}\theta_{\text{MLE}} &= \arg \max_{\theta} \sum_{i=1}^n \log p(y^{(i)} | \mathbf{x}^{(i)}; \theta) \\ &= \arg \max_{\theta} \sum_{i=1}^n \left[y^{(i)} \log p(y^{(i)}=1 | \mathbf{x}^{(i)}; \theta) + (1 - y^{(i)}) \log (1 - p(y^{(i)}=1 | \mathbf{x}^{(i)}; \theta)) \right]\end{aligned}$$

- Modelde değiştirin ve verim için negatif alın

Logistic regression objective:

$$\begin{aligned}\min_{\theta} J(\theta) \\ J(\theta) = - \sum_{i=1}^n \left[y^{(i)} \log h_{\theta}(\mathbf{x}^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(\mathbf{x}^{(i)})) \right]\end{aligned}$$

Lojistik Regresyon

- Hedefin Arkasındaki Sezgi

$$J(\boldsymbol{\theta}) = - \sum_{i=1}^n \left[y^{(i)} \log h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)})) \right]$$

- Tek bir örneğin maliyeti

$$\text{cost}(h_{\boldsymbol{\theta}}(\mathbf{x}), y) = \begin{cases} -\log(h_{\boldsymbol{\theta}}(\mathbf{x})) & \text{if } y = 1 \\ -\log(1 - h_{\boldsymbol{\theta}}(\mathbf{x})) & \text{if } y = 0 \end{cases}$$

- Amaç fonksiyonunu şu şekilde yeniden yazabilir:

$$J(\boldsymbol{\theta}) = \sum_{i=1}^n \text{cost}(h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}), y^{(i)})$$

- Doğrusal regresyonla karşılaştıran:


$$J(\boldsymbol{\theta}) = \frac{1}{2n} \sum_{i=1}^n \left(h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) - y^{(i)} \right)^2$$

Lojistik Regresyon

- Hedefin Arkasındaki Sezgi

$$\text{cost}(h_{\theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\theta}(\mathbf{x})) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(\mathbf{x})) & \text{if } y = 0 \end{cases}$$

Aside: Recall the plot of $\log(z)$




Lojistik Regresyon

- Hedefin Arkasındaki Sezgi

$$\text{cost}(h_{\theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\theta}(\mathbf{x})) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(\mathbf{x})) & \text{if } y = 0 \end{cases}$$

- Eğer $y=1$ ise,
- Eğer tahmin doğruysa $\text{cost} = 0$
- $h_0(x) \rightarrow 0$, $\text{cost} \rightarrow \infty$ olarak
- Daha büyük hataların daha büyük cezalar alması gerektiğine dair sezgiyi yakalar
- Örneğin $h_0(x) = 0$ olarak tahmin edin ama $y=1$




Lojistik Regresyon

- Hedefin Arkasındaki Sezgi

$$\text{cost}(h_{\theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\theta}(\mathbf{x})) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(\mathbf{x})) & \text{if } y = 0 \end{cases}$$

- Eğer $y=1$ ise,
- Eğer tahmin doğruysa $\text{cost} = 0$
- $h_0(x) \rightarrow 0$, $\text{cost} \rightarrow \infty$ olarak
- Daha büyük hataların daha büyük cezalar alması gerektiğine dair sezgiyi yakalar
- Örneğin $h_0(x) = 0$ olarak tahmin edin ama $y=1$



Lojistik Regresyon

- Düzenli Lojistik Regresyon

$$J(\boldsymbol{\theta}) = - \sum_{i=1}^n \left[y^{(i)} \log h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)})) \right]$$

- Lojistik regresyonu tam olarak daha önce olduğu gibi düzenleyebiliriz:

$$\begin{aligned} J_{\text{regularized}}(\boldsymbol{\theta}) &= J(\boldsymbol{\theta}) + \frac{\lambda}{2} \sum_{j=1}^d \theta_j^2 \\ &= J(\boldsymbol{\theta}) + \frac{\lambda}{2} \|\boldsymbol{\theta}_{[1:d]}\|_2^2 \end{aligned}$$

Lojistik Regresyon

- Lojistik Regresyon için Gradyan İniş (Gradient Descent)

$$J_{\text{reg}}(\boldsymbol{\theta}) = - \sum_{i=1}^n \left[y^{(i)} \log h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)})) \right] + \frac{\lambda}{2} \|\boldsymbol{\theta}_{[1:d]}\|_2^2$$

- $\min_{\boldsymbol{\theta}} J(\boldsymbol{\theta})$ iste
- $\boldsymbol{\theta}'$ yi başlat
- Yakınsama kadar tekrarlayın

$$\theta_j \leftarrow \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\boldsymbol{\theta})$$

j=0..d için eşzamanlı güncelleme

- $h_0(x)$ 'deki $\exp()$ ile iptal etmek için ($\ln = \log_e$) doğal logaritmasını kullanın

Lojistik Regresyon

- Lojistik Regresyon için Gradyan İniş (Gradient Descent)

$$J_{\text{reg}}(\boldsymbol{\theta}) = - \sum_{i=1}^n \left[y^{(i)} \log h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)})) \right] + \frac{\lambda}{2} \|\boldsymbol{\theta}_{[1:d]}\|_2^2$$

- $\min_{\boldsymbol{\theta}} J(\boldsymbol{\theta})$ iste
- $\boldsymbol{\theta}'$ yi başlat
- Yakınsama kadar tekrarlayın

j=0..d için eşzamanlı güncelleme

$$\begin{aligned} \theta_0 &\leftarrow \theta_0 - \alpha \sum_{i=1}^n \left(h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) - y^{(i)} \right) \\ \theta_j &\leftarrow \theta_j - \alpha \left[\sum_{i=1}^n \left(h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) - y^{(i)} \right) x_j^{(i)} + \lambda \theta_j \right] \end{aligned}$$

Lojistik Regresyon

- Lojistik Regresyon için Gradyan İniş (Gradient Descent)

- θ 'yı başlat
- Yakınsama kadar tekrarlayın

$$\theta_0 \leftarrow \theta_0 - \alpha \sum_{i=1}^n \left(h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)} \right)$$

j=0..d için eşzamanlı güncelleme

$$\theta_j \leftarrow \theta_j - \alpha \left[\sum_{i=1}^n \left(h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)} \right) x_j^{(i)} + \lambda \theta_j \right]$$


- Bu, doğrusal regresyonla AYNI görünüyor !!!
- 1/n sabitini yok say
- Ancak, modelin formu çok farklıdır:

$$h_{\theta}(\mathbf{x}) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

Lojistik Regresyon

- Çok Sınıflı Sınıflandırma

- İkili Çoklu



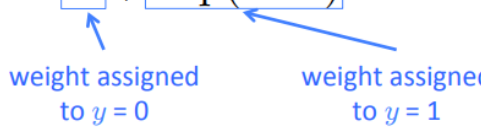
- Hastalık teşhisi: sağlıklı / soğuk algınlığı / grip / pnömoni
- Nesne sınıflandırması: masa / sandalye / monitör / kitaplık

Lojistik Regresyon

- Çok Sınıflı Sınıflandırma

- 2 sınıf için:

$$h_{\theta}(x) = \frac{1}{1 + \exp(-\theta^T x)} = \frac{\exp(\theta^T x)}{\boxed{1} + \boxed{\exp(\theta^T x)}}$$


weight assigned to $y = 0$ weight assigned to $y = 1$


- $\{1, \dots, C\}$ C sınıfları için:

$$p(y = c \mid x; \theta_1, \dots, \theta_C) = \frac{\exp(\theta_c^T x)}{\sum_{c=1}^C \exp(\theta_c^T x)}$$

- Softmax denir

Lojistik Regresyon

- Çok Sınıflı Sınıflandırma
 - Bire karşı diğerlerini bölün



- $y = i$ olasılığını tahmin etmek için her i sınıfı için bir lojistik regresyon sınıflandırıcı eğitin.

$$h_c(\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}_c^\top \mathbf{x})}{\sum_{c=1}^C \exp(\boldsymbol{\theta}_c^\top \mathbf{x})}$$

Lojistik Regresyon

- Çok Sınıflı Lojistik Regresyon Uygulaması
 - c sınıfı için model olarak:

$$h_c(\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}_c^\top \mathbf{x})}{\sum_{c=1}^C \exp(\boldsymbol{\theta}_c^\top \mathbf{x})} \text{ kullanın.}$$

- Gradyan iniş, tüm modeller için tüm parametreleri aynı anda günceller.
 - Öncekiyle aynı türev, sadece yukarıdaki $h_c(x)$ ile.
- Sınıf etiketini en olası etiket olarak tahmin edin.

$$\max_c h_c(\mathbf{x})$$

Lojistik Regresyon